

Dos propuestas y una decisión con datos

Cargo Claro y Reclamo sin sorpresas. Propuesta para el Factored AI & Data Hackathon 2026.


1. Resumen

Tenemos dos candidatas fuertes para el mismo reto. **A, Cargo Claro**, resuelve el cargo no reconocido antes de que se convierta en disputa. **B, Reclamo sin sorpresas**, atiende lo que pasa después de que el cliente ya reclamó: seguimiento, fecha honesta de resolución y escalación antes de que el caso explote. Comparten arquitectura, stack y reparto de roles. No las combinamos, porque las bases dicen que más workflows no suman puntos [10]. El Día 1 corremos las verificaciones de ambas y elegimos con evidencia (sección 4).

2. Propuesta A: Cargo Claro

Problema. Muchos cargos "no reconocidos" son legítimos: una preautorización, una compra en otra moneda, una suscripción o una compra con otra tarjeta propia. Mastercard reporta que casi la mitad de los consumidores alguna vez disputó un cargo que luego resultó legítimo, y que Sicredi redujo 22% sus contracargos mostrando mejor información del comercio [1].

Solución. Workflow de *transaction-dispute intake* con dos salidas. Unos root cause detectors deterministas (duplicado de pipeline frente a doble cobro real, preautorización, conversión de moneda, recurrencia, comercio habitual en la línea de Visa CE 3.0 [8]) explican el cargo con evidencia calculada. Un risk guard impide explicar como legítimo un cargo de alto riesgo. Si no hay causa o el cliente insiste, ofrece un bloqueo informado (qué suscripciones fallarían) y entrega un case file al analista.



Componente de ML. Sequence model autosupervisado por cliente, inspirado en nuFormer de Nubank [2][3] y el Payments Foundation Model de Stripe [4], con predicción por campo (categoría, monto, país, hora, canal): la sorpresa por campo es la explicación del riesgo. Label de evaluación: `is_fraud`, temporal split. Baselines: reglas y LightGBM. El umbral de deflexión se elige con Conformal Risk Control [6] para acotar la tasa de fraude explicado como legítimo.

3. Propuesta B: Reclamo sin sorpresas

Problema. Una parte grande del volumen de un contact center es *failure demand* [9]: clientes que vuelven a llamar porque su problema no se resolvió o porque nadie les dijo cuándo se resolvería. "¿Cómo va mi reclamo?", "es la tercera vez que llamo". Esos contactos saturan la operación, empeoran la satisfacción y terminan en quejas al regulador.

Solución. Workflow de *complaint follow-up* con tres piezas. (1) Seguimiento automático: el cliente se autentica, el sistema identifica a cuál de sus reclamos se refiere y responde con el estado verificado desde complaints. Es solo lectura, de riesgo bajo y alta automatización. (2) Fecha honesta: un modelo time-to-event estima cuándo se resolverá y la entrega con un intervalo calibrado. (3) Escalación proactiva: si el riesgo de incumplir el SLA o de terminar en el regulador es alto, el caso pasa a un humano con el historial completo antes de que el cliente vuelva a llamar.



Componentes de ML. (a) Survival model sobre resolution_days que trata los reclamos abiertos como observaciones censuradas, con intervalos por conformalized survival analysis [7]. Métrica: C-index e integrated Brier score contra un baseline de mediana por categoría. (b) Clasificadores de riesgo de sla_breached y de reclamo posterior por el canal Regulator, con features solo disponibles al momento del contacto (nunca fechas de cierre). Línea ética: el sistema nunca desalienta ir al regulador; menciona el derecho a reclamar cuando corresponde.

4. Comparación y regla de decisión

Criterio	A: Cargo Claro	B: Reclamo sin sorpresas
Consistencia con las bases	Alta	Alta
Respaldo en datos	Media: depende de patrones sintéticos	Alta: labels nativas en complaints
Diferenciación frente a otros equipos	Media-alta: el workflow es popular	Alta: casi nadie lo elegirá
Safe automated resolution esperada	Media	Alta: operación de solo lectura
Impacto de negocio	Disputas evitables, handle time	Contactos repetidos, SLA, quejas al regulador
Impacto en el cliente	Respuesta inmediata y bloqueo informado	Certeza sobre su caso y su fecha
Efecto en la demo	Alto	Medio: se compensa con la escena del cliente reincidente
Rigor de ML distintivo	Sequence model + conformal risk control	Survival con censura + intervalos conformales
Viable con 2 personas en 8 días	Media	Alta

Diferenciación común. Lo esperable de otros equipos es chat + tools + RAG + clasificador + resumen de handoff, evaluado en una sola corrida. Ambas propuestas agregan una garantía estadística sobre su error más caro, un modelo cuya explicación sale del propio modelo y no del LLM, grading por estado final con pass^k [5] y un naive LLM agent como baseline visible en la demo.


Regla de decisión al cierre del Día 1 (umbrales sugeridos). Elegimos A si al menos tres de los cinco root causes aparecen con prevalencia de 1% o más en compras con tarjeta reales y los cargos no reconocidos son un motivo de contacto relevante. Elegimos B si identificamos contactos de seguimiento posteriores a un reclamo y un modelo simple sobre resolution_days logra un C-index de 0.65 o más frente a 0.5. Si ambas pasan, elegimos A por impacto en la demo; si solo B pasa, B; si ninguna, B con la limitación declarada, porque sus labels existen aunque tengan poca señal.

5. Hipótesis y query plan del Día 1

#	Hipótesis	Query o prueba	Si falla
C1	Calidad real frente a la declarada	Duplicados, nulos y huérfanos por tabla; duplicado de PK frente a contenido	Se documenta y se ajustan contracts
A1	Cargos no reconocidos son demanda relevante	contact_reason y categorías de complaints por país, canal y año	Descartar A
A2	Hay reclamos por cargos cerrados como cargo válido	Texto de resolution y compensation_granted en esa categoría	Tesis solo con evidencia de industria

#	Hipótesis	Query o prueba	Si falla
A3	Existen preautorizaciones, moneda extranjera y dobles cobros	Pares Pending a Reversed; currency distinta a la local; mismo comercio y monto en minutos	Detectores con fixtures declarados
A4	Hay recurrencia y estructura temporal por cliente	Periodicidad cercana a 30 días por product_id y merchant; next-event contra frecuencias	Se cae el sequence model; queda LightGBM
A5	fraud_score no filtra a is_fraud	AUC de fraud_score solo	Se excluye como baseline
B1	Hay failure demand medible	Contactos del mismo cliente entre creation_date y closing_date; contact_reason de seguimiento; requires_followup	Descartar B
B2	resolution_days es predecible	Cox o gradient boosting survival con features de ingreso; C-index	Solo seguimiento, sin ETA
B3	Hay volumen en canal Regulator y SLA incumplido	Conteo por reception_channel y sla_breached; orden temporal con contactos previos	Se usa solo el riesgo de SLA
B4	complaints se une a interacciones	origin_interaction_id y join por cliente y fecha; tasa de match	Limitación declarada

6. Arquitectura común



La plataforma es la misma para ambas. Solo cambian los modelos, los detectores y las tools del mock bank:

Capa	Si elegimos A	Si elegimos B
Modelos	Sequence model de riesgo + LightGBM baseline + conformal threshold	Survival model + intervalos conformales + clasificadores de SLA y regulador
Lógica determinista	Root cause detectors en SQL (moneda con daily_exchange_rates, Pending y Reversed, recurrencia)	Máquina de estados del reclamo y reglas de SLA como synthetic policy
Tools	get_transactions, explain_charge, block_card, open_claim	list_complaints, get_complaint_status, estimate_resolution, escalate_case
Case inbox	Timeline del cargo, factores de riesgo, causas descartadas	Historial de contactos, estado, ETA, razón de la escalación

7. Tareas por persona

Aldair (data science)	Martín (web y deployment)
Query plan del Día 1 y decisión. Data pipeline, contracts, lineage y fixture de late arrivals. Baseline metrics del status quo. Modelos, baselines y calibración conformal. Detectores o reglas del reclamo. Policy rules as code. Prompts y structured outputs con PII redaction. Escenarios con hidden state, customer simulator, set en portugués y error analysis. Data card y model cards.	Repo, docker-compose y CI. Mock identity y mock bank services. Orchestrator y action gateway. Chat, case inbox y ops panel. Case store, audit log y export PDF. Tracing (OpenTelemetry + Langfuse o Phoenix), bounded retries y safe fallback. Deployment y setup en un comando. Casi todo su trabajo no depende de la decisión del Día 1.

Compartido: la state machine (Aldair la especifica, Martín la implementa), la demo y el ensayo. Interfaces congeladas el Día 1: esquemas de gold, contratos de las tools, esquema de eventos del audit log y formato JSON del eval report.

8. Cronograma de 8 días

Día	Aldair	Martín	Checkpoint
1	Ingesta, quality report, query plan A y B	Repo, contratos v1, esqueleto web, deploy vacío	Decisión A o B
2	Silver y gold, baseline metrics, dataset del modelo	Mock identity y mock bank sobre gold	Datos listos
3	Detectores o reglas, policy, prompts, baseline del modelo	State machine, gateway, case store	Happy path en terminal
4	Primeros 40 escenarios y grader	Chat e inbox conectados, staging	End-to-end en español
5	Modelo principal, set en portugués, customer simulator	Tracing, ops panel, export PDF	Portugués funcionando
6	Calibración conformal, corrida completa contra baselines	Sesión expirada, acceso cruzado, tool failures, prompt injection	Primeros resultados
7	Error analysis, pass ^k , breakdowns por idioma y segmento	Fixes, p50 y p95, clean-clone test	Feature freeze
8	Data card, model cards, write-up	Deploy final, README, grabación de demo	Entrega y ensayo

Orden de recorte: primero el modelo avanzado (queda el baseline y se reporta el intento), luego el ops panel en vivo (queda un reporte estático), luego Postgres (queda SQLite). No se recortan portugués, casos adversos, evaluación contra baseline, latencia ni costo.

9. Métricas y supuestos

- **Safe automated resolution** sobre todos los casos in-scope, más la tasa de casos donde se intentó automatizar.
- **Unsafe outcomes** con conteos y denominadores: en A, fraude explicado como legítimo (is_fraud); en B, estado o fecha incorrectos y divulgación de reclamos de otro cliente.
- **Escalation quality** (faltantes e innecesarias), completitud del case file, pass^k, p50 y p95, costo por caso intentado y por resolución automática, y resultados por idioma, país y segmento.
- El dataset es sintético y solo trae español de México, Colombia y Argentina. El portugués es team-generated (clientes brasileños residentes) y se declara así. De MED 2.0 [11] solo tomamos principios de diseño.
- Las garantías conformales asumen intercambiabilidad; reportamos también su cumplimiento empírico en el test temporal. Las credenciales de AWS viven solo en variables de entorno.

10. Fuentes

- [1] Mastercard. Ethoca Consumer Clarity.
mastercard.com/global/en/business/cybersecurity-fraud-prevention/dispute-management/ethoca-consumer-clarity.html
- [2] Nubank AI Core. "Your Spending Needs Attention: Modeling Financial Habits with Transformers". arXiv:2507.23267, 2025.
- [3] Building Nubank. "How Nubank uses transformers to model financial habits at scale", 2026. building.nu.com
- [4] PaymentsJournal. "Stripe's AI model touted to be more effective against fraud", 8 de mayo de 2025.
- [5] Yao, Shinn, Razavi, Narasimhan (Sierra). "tau-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains". arXiv:2406.12045, 2024.
- [6] Angelopoulos, Bates, Fisch, Lei, Schuster. "Conformal Risk Control". ICLR 2024. arXiv:2208.02814.
- [7] Candès, Lei, Ren. "Conformalized Survival Analysis". Journal of the Royal Statistical Society Series B, 2023. arXiv:2103.09763.
- [8] Visa. Evolution of Compelling Evidence, Merchant FAQs (CE 3.0), marzo de 2023.
- [9] Seddon, J. "Freedom from Command and Control". Vanguard Press, 2003 (concepto de failure demand).
- [10] Factored. AI & Data Hackathon 2026, Problem Statement; LATAM Bank Complete Data Dictionary v1.0.0.
- [11] Agência Brasil. "Novas regras de segurança do Pix entram em vigor" (MED 2.0), febrero de 2026.